

今日 16:28

global Backpropagation に依存せず、自身の予測モデルの不十分性を検出する方法は、原始的な生物の場合どうやっているのか？人間はその延長上なのか？

原始的な生物では、かなり根本的に「global Backpropagation 的なもの」は必要ありません。むしろ、生物が最初に獲得したのは、

「世界モデル全体が間違っているか」を判定する仕組みではなく、
「予測した結果と、実際に生存に効いた結果のズレを、局所的な状態変化として検出する仕組み」

だったと考える方が自然です。

典型例が細菌の走化性です。大腸菌などは、空間地図を持って「こちらに栄養がある」と推論しているわけではありません。少し前の化学物質濃度を内部状態として保持し、現在値との差を取り、良くなったか悪くなったかによって遊泳方向を変えます。そして受容体のメチル化などによる適応機構で基準値を更新する。これは非常に小さな「予測誤差 + 内部モデル更新」と見なせます。  Annual Reviews

さらに興味深いのは、微生物ですら単純な反応だけでなく、環境中の時間的相関を利用して「次に何が起こるか」を先回りすることがある点です。たとえば、環境Aの後に環境Bが規則的に来るなら、Aを検知した時点でBへの準備を始める。つまり非常に原始的な生物でも、進化によって埋め込まれた予測モデルを使っていると考えられます。  Annual Reviews

ここから見ると、あなたの問いにはかなり面白い答えが出ます。

「モデルが不十分である」とどう検出するのか

原始的な生物はおそらく、モデルそのものを評価していません。

代わりに、

prediction → action → consequence

という局所ループを持ち、

$$e_t = y_t - \hat{y}_t$$

のようなズレが長時間消えない、あるいは生存に重要な変数が悪化することで、

「今の内部状態／制御則では説明・制御できていない」

ことを検出します。

これはニューラルネットで言えば、巨大なend-to-end lossを逆伝播するのではなく、

$$e_1, e_2, \dots, e_n$$

という多数のローカルなprediction errorが、それぞれ自分の近傍だけを変更する方式です。

実際、脳の学習についても、厳密なglobal BPは生物学的にはかなり不自然と考えられており、局所シナプス可塑性やpredictive codingなどが代替候補として研究されています。 [PubMed Central... +1](#)

ここで重要なのは、「誤差を減らす」と「モデルが足りないと気づく」は別問題だということです。

生物はおそらく後者について、少なくとも次のような信号を使っています。

1. prediction errorが消えない
2. 同じ行動をしても結果の分散が増える
3. 恒常性変数が制御範囲を外れる
4. 既存の刺激 - 行動対応では改善しない
5. 未知の刺激・状態が頻発する

つまり、

$$\text{model inadequacy} \approx \text{persistent / irreducible prediction error}$$

です。

ただし、この考え方にはさらに重要な一段があります。

人間はその延長なのか

かなりの部分で **Yes** だと思います。ただし途中で質的な追加があります。

人間でも最下層では、

- 血糖
- 体温
- CO₂
- 浸透圧
- 姿勢
- 視覚予測
- 運動予測

など、多数の局所予測・局所制御ループが動いています。

脳が将来の身体需要を予測して先回りして調整するという考え方は、現在では **allostasis** としてかなり確立した枠組みになっています。 [E サイエンスダイレクト +1](#)

ところが人間では、これに

「誤差が大きい」

→「このモデルのパラメータが悪い」

→「いや、このモデルの構造そのものが悪いのでは？」

という階層が追加される。

ここが非常に重要です。

細菌なら、

栄養が減った → tumbleを増やす

程度ですが、人間では、

この実験結果は予測と違う

↓

パラメータを調整する

↓

それでも合わない

↓

仮説そのものを捨てる

まで行ける。

つまり、

parameter learning → model selection → model invention

という階層化が起きています。

これは、以前話していた**「問いを立てる能力」**ともかなり直結します。

モデルが予測不能な領域に入ったとき、

普通の機械学習なら

$$\nabla_{\theta} L$$

を計算して θ を動かします。

しかし生物は場合によっては、

$$M_{\theta} \rightarrow M'_{\phi}$$

と、モデルそのものを切り替える。

そして私は、これが生物の知能で非常に重要な部分だと思います。

さらに踏み込むと、原始生物から人間までを一本の線として見るなら、進化はおそらく

prediction error → local adaptation → action exploration → model switchin

という能力を積み重ねてきた、と見ることができます。

Global Backpropagationは、このうち非常に特殊な解法です。

生物は逆に、

多数の閉ループ制御系 + 局所予測誤差 + 探索 + 選択

で学習している可能性が高い。

これなら、なぜ生物が **global BPなしで巨大な階層系を学習できるのか** がかなり自然に説明できます。

そして、あなたが以前考えていた「BPを使わない学習前中間表現の再構成」という発想にもつながります。もしかすると重要なのは、**誤差をネットワーク全体に戻すことではなく、どの内部表現が予測不能になったかを検出して、その局所表現だけを再構成すること**なのかもしれません。

この方向は、predictive codingだけでなく、active inference、homeostatic RL、local learning、continual learning、world-modelのuncertainty推定を一つの枠で見ると、かなり面白い研究テーマになります。  サイエンスダイレクト



今日 22:29

モデルを切り替えるというのは、気に入りました。この考えは、自分の質問からあなたが今考えたというより、研究として今割と標準的な見方として広まっているのえしょうか？

「モデルを切り替える」という発想そのものは、私が今ここで作ったものではありません。**神経科学・認知科学**ではかなり古くから**存在する有力な考え方**です。ただし、前の回答で私がやったように、

原始生物の局所適応 → 予測誤差 → モデル不十分性の検出 → モデル切替 → 人間の仮説生成

までを一本の進化的な線として結んだ部分は、標準理論そのものではなく、複数の研究領域を私が統合して解釈したものです。

特に近いのが、1990年代から研究されてきた **Multiple Internal Models** です。Wolpert、Kawatoらの有名な枠組みでは、脳が一つの巨大な内部モデルを更新し続けるのではなく、

$$M_1, M_2, \dots, M_n$$

という複数のforward/inverse modelを持ち、その時々 の文脈に応じて適切なモデルの寄与を変える、あるいは切り替えると考えます。Kawatoの1999年のレビューには、すでに「multiplicity and switching of internal models」が主要論点として明記されています。 [E サイエンスダイレクト +1](#)

さらにWolpertらの **Multiple Paired Forward and Inverse Models** ではかなり明示的です。各 forward modelが、

$$\hat{s}_{t+1}^{(i)} = F_i(s_t, a_t)$$

と次状態を予測し、実際の

$$s_{t+1}$$

とのprediction errorによって「いまどのモデルが世界をうまく説明しているか」を評価します。そして対応するcontrollerの重みを変える。つまり概念的には、

$$P(M_i \mid \text{observations})$$

を更新しているのに近い。 [E サイエンスダイレクト +1](#)

ここは、さっきあなたが気に入った話とほぼ同じです。

ただし非常に重要な注意があります。「人間の脳は常に複数モデルを明確に保持してswitchしている」と確定したわけではありません。実験によっては、異なる力場を交互に提示しても、人間が二つの内部モデルをうまく切り替えられず、一つのモデルとして平均化するような結果も出ています。つまりmultiple-model/switchingは有力な計算原理ですが、脳がいつ・どこで・どの粒度でそれを実装しているかは未解決です。 [PubMed](#)

そしてこの考え方は運動制御だけに留まりません。2009年のレビューでは、内部モデルのswitchingを、道具使用だけでなく、長期目標、他者予測、社会認知、言語などの高次認知まで拡張できる可能性が議論されています。 [PubMed](#)

ここまではかなり既存研究です。

一方、私が先ほどかなり強く踏み込んだ、

prediction error → model inadequacy detection → model switching → model

という階層は、この形で標準説になっているわけではありません。

むしろ、この最後の二段にはまだ大きな研究上の穴があります。

「既存モデルの更新」と「モデルを捨てる」は違う

普通の学習では、

$$M(\theta)$$

があって、

$$\theta \rightarrow \theta'$$

とします。

これはgradient descentでもHebbian learningでもRLでもできます。

ところが、

$$M_1 \rightarrow M_2$$

は別問題です。

もっと極端には、

$$\{M_1, \dots, M_n\} \rightarrow M_{n+1}$$

つまり、まだ存在しなかったモデルを作る。

これが人間の仮説形成、概念形成、あるいはあなたが以前言っていた「問いを立てる」にかなり近い。

現在の研究では、この問題はそれぞれ別の名前で研究されています。

- Bayesian model selection
- latent cause inference
- context inference
- structure learning
- causal discovery
- task-set switching
- schema formation
- hierarchical reinforcement learning

などです。

ただ、これらを

「生物は自分の予測器の破綻を検出すると、内部モデルの構造を作り替える」

という単一原理として捉えるところまでは、まだ統一理論にはなっていません。

ここがむしろ面白いところです。

そして、あなたの最初の問いに戻ると、私は少し見方を修正した方がよいと思っています。

最初は、

prediction errorが大きい → モデルを切り替える

と単純化しました。

しかし、それだけでは駄目です。

なぜならprediction errorが大きい理由には、

- A: パラメータが間違っている
- B: 観測ノイズが大きい
- C: 世界が変化した
- D: 既知の別モデルの状況になった
- E: そもそもモデル族が間違っている

があるからです。

知能にとって本当に難しいのは、この識別です。

つまり重要なのは単なる

$$|y - \hat{y}|$$

ではなく、

「この誤差は、今のモデルを学習し続ければ消える種類なのか？」

を判断することです。

もし

$$\frac{dE}{d(\text{learning})} \approx 0$$

つまり学習しても誤差が系統的に減らないなら、

パラメータ更新ではなく、モデルを変えるべきではないか

というメタ信号になります。

私はこれが、global BPに代わる学習原理を考えるうえでかなり重要だと思います。

要するに、

誤差そのものではなく、「誤差の学習可能性」を監視する

わけです。

そしてこれは、単純な生物でも原型があり得ます。

ある制御反応を繰り返しているのにhomeostasisが回復しないなら、別の行動様式へ移る。より高度な動物なら別のpolicy、さらに人間なら別の概念・仮説へ移る。

そう考えると、

細胞の状態遷移 → 行動モード切替 → 内部モデル切替 → 仮説切替

はかなり連続的に見えてきます。

この「誤差の大きさではなく、誤差が減らないことをモデル破綻の信号にする」という方向は、前回より一段掘る価値があります。Global BPを不要にするだけでなく、「いつ学習をやめて別の表現を作るか」という、現在のニューラルネットがかなり苦手の問題に直接つながるからです。

📄 🗣️ 📌 🔄 ...

どういうわけか、生物は内部に多様なモデルを持ち、それらを組み合わせ、ある程度の変種のモデルを持つことができるようですね。おそらくは、自然淘汰と進化の過程でDNAに叩き込まれ保存された仕組みをベースにしているとおもいますが、組み合わせたり多少の適用をしたモデルを多数内部に持たないことには対応できないので、これは確実にそうなのでしょう。問題はその仕組みですね。もしその組み合わせる仕組みがるとするなら、BPがなくても、モデルを比較して採用する。あるいは何らかの変種をその場でつくって、最善を選ぶことができるでしょう。それが疑問をもつと会話間を持つ仮説を持つということでしょう。しかしこの仕組みをニューラルネットワークの、成長と発達として、これまでの研究で詳細まで観察されているのでしょうか？ 原理的にこれを安定的にする閉ループはいられているのでしょうか？

8s考えました >

かなり詳細まで観察されています。ただし結論を先に言うと、「候補回路を多数つくる → 比較する → 良いものを残す → 悪いものを消す → 全体を安定化する」という各部品はかなり分かっている一方、それが高次の“仮説生成・モデル選択”までどうつながるかは、まだ統一理論になっていません。

一番重要なのは、発達中の脳が実際にかなり「作りすぎてから削る」ことです。人間の大脳皮質でも、発達初期にはシナプスが過剰形成され、その後かなりの割合が除去されます。これは単なる比喻ではなく、解剖学的・発生学的に観察されている現象です。 ● 国立生物工学情... +1

つまり発生は、

設計図から完成回路を直接生成

ではなく、むしろ

多数の候補結合を生成 → 活動させる → 選択的に安定化 → 不要結合を除去

に近い。

この意味では、あなたが想像している方式にかなり近いです。

さらに面白いのは、感覚入力はまだ十分でない発生初期から、神経回路は**自発活動**をします。網膜、脊髄、海馬、皮質などで、発達期特有のspontaneous activityが観測されています。この活動がニューロンの生存、軸索・樹状突起の成長、シナプス形成などに影響します。つまり「外界から教師データが来るまで何もしない」のではありません。 ● PubMed Central... +1

かなり乱暴に機械学習風を書けば、

genetic prior → variation → internal simulation / spontaneous activity → en

です。

ここにはglobal BPは必要ありません。

そして、「どれを残すか」もかなり局所的です。神経活動に依存してシナプスの一部が維持・強化され、一部が除去されます。現在では、microgliaやastrocyteまでこの選択に関与していることが分かっています。補体系や“eat-me / don't-eat-me”に相当する分子信号によって、弱い・不要な結合を物理的に除去する機構まで研究されています。 ⓘ Nature +2

したがって、本当に

variation + competition + selection + elimination

が神経発達中に起きています。

では、なぜ暴走しないのか

ここが質問の「安定した閉ループ」に対応します。

最もよく知られている一つが **homeostatic plasticity** です。

Hebbian learning だけなら、

よく発火する結合

→ 強くなる

→ さらに発火する

→ さらに強くなる

という正帰還が起きます。

数式的には、

$$\Delta w_{ij} \propto x_i x_j$$

だけでは、容易に発散します。

脳にはこれとは逆向きの遅いフィードバックがあります。

例えば、あるニューロンの平均発火率を

$$\bar{r}$$

目標値を

$$r^*$$

とすると、概念的には

$$\Delta w_{\text{homeo}} \propto r^* - \bar{r}$$

のような補正をかけます。

活動が多すぎれば全体の感度を下げ、少なすぎれば上げる。

実際には、

- synaptic scaling
- intrinsic excitability調整
- E/I balance
- dendrite / axon connectivity変更
- inhibitory circuit調整

など複数の機構があります。  スプリングァーリンク +2

したがって一番単純化すると、

局所的な競争的学習 + ゆっくりした恒常性制御

という二重ループになっています。

これは非常に重要です。

Hebbian plasticityが

差を拡大する

役割を持ち、

homeostatic plasticityが

全体を破綻させない

役割を持つ。

つまり、

探索・分化 ↔ 安定化

を別の機構に分離している。

これはBPよりかなり違った設計思想です。

実際には「モデル候補を作って競争させる」にかなり近い

この考え自体は、Edelmanが **Neural Darwinism / Neuronal Group Selection** としてかなり明示的に提案しています。

Edelmanの基本構図は、

1. 発生によって多様な神経回路ができる
2. 経験・行動によって活動パターンが生じる
3. 価値に結び付く回路が選択的に強化される
4. neuronal groupとして安定化する

というものです。 [E サイエンスダイレクト +1](#)

なので、あなたの発想にはかなり近い先行思想があります。

ただし注意が必要で、現在では「Darwinism」という言葉は少し強すぎると考えられています。

自然選択なら、

variation + selection + replication + inheritance

が必要ですが、神経回路の場合、候補回路が自己複製して子孫を作るわけではない。

そのため現在では、

selectionistではあるが、strictなDarwinian processではない

という批判があります。  PubMed +1

この区別はかなり大切です。

ただし、ここから先がまだ未解決です

「シナプス候補を作って選ぶ」まではかなり分かっています。

しかし、あなたが本当に聞いている、

ニューロン群Aがモデル M_1 、
ニューロン群Bがモデル M_2 、
ニューロン群Cが M_1, M_2 の組合せ変種をつくり、
prediction errorを比較して勝者を採用する

というところまで、直接観察されているわけではありません。

ここにはかなり大きなスケール差があります。

シナプスレベルでは、

strengthen / weaken / create / eliminate

を直接観察できます。

神経回路レベルでも、

representation A vs representation B

の競争は観察できます。

しかし、

「この回路は世界モデルAを表している」

と同定することは非常に難しい。

さらに、

$M_1, M_2 \rightarrow M_3$

というモデルの合成を神経回路として追跡するのは、現在でもかなり難しい問題です。

ただ、私ならここを3段階に分けます

あなたの仮説を神経科学的に言い換えると、こうなります。

第1段階：構造的 variation

発生によって、

$$C_1, C_2, \dots, C_N$$

という少しずつ違う回路を大量につくる。

DNAは完成した配線を書いているわけではなく、

「どう成長するか」

「何に反応して伸びるか」

「何を消すか」

という**生成規則**を記述する。

これはかなり確実です。

第2段階：activity-dependent selection

候補回路を活動させ、

$$C_i \rightarrow \hat{y}_i$$

結果を環境・身体から返してもらう。

活動の相関、報酬、neuromodulator、恒常性などで、

$$C_i$$

の生存・強化を変える。

ここもかなり分かっています。

第3段階：compositional generation

既存の

$$C_a, C_b$$

を利用して、

$$C_c = f(C_a, C_b)$$

という新しいモデルを形成する。

ここがまだかなり不明瞭です。

おそらく、

- hippocampal replay
- cortical recombination
- dendritic computation
- recurrent dynamics
- hippocampal–cortical consolidation
- schema learning
- basal ganglia gating

などが関係していますが、「これがモデル合成アルゴリズムです」と言えるところまで来ていません。

そして、ここから一つ重要な推測ができます。

生物がやっていることは、「モデルをコピーして突然変異させる」より、「過剰な接続可能性の中で一時的な回路を発火させ、その一部を固定する」に近いのではないか。

つまり、

$$M_i \rightarrow M'_i$$

と明示的にモデルを複製する必要はない。

大きなrecurrent networkの内部で、

$$z_t^{(1)}, z_t^{(2)}, z_t^{(3)}, \dots$$

という複数の活動パターンが自然に発生する。

そのうち、あるものがうまく結果を予測したり行動を成功させたりすると、

transient activity → synaptic stabilization

によって構造になる。

これは、

動的な仮説 → 選択 → 構造化されたモデル

という構図です。

私は、こちらの方が「突然モデルを生成する」より生物学的には自然だと思います。

そして発達期に見られる **spontaneous activity + structural plasticity + pruning + homeostasis** は、そのためのかなり良い実装候補です。

発達中の神経回路は接続がどんどん変わっているのに、驚くほど活動レベルを維持できます。これは実際、homeostatic plasticity 研究の中心的問題です。  PubMed Central...

したがって、かなり抽象化してしまえば、

Generate:	spontaneous activity + structural growth
Evaluate:	sensory consequence + reward + homeostasis
Select:	Hebbian / neuromodulated plasticity
Delete:	pruning
Stabilize:	homeostatic plasticity + inhibition

という閉ループそのものは、部品レベルならかなり実証されていると言っていいと思います。

一方で、

これが人間の「仮説を立てる」にどうスケールするか

はまだ空白が大きい。

ここはむしろ、あなたが考えているBP代替の研究としてかなり面白いと思います。既存NNで真似するなら、**固定ネットワークをglobal lossで更新するのではなく、「一時的なサブネットワークを多数生じさせる → 局所予測誤差と価値で競合 → 一部を固定 → homeostatic normalization → 不要回路をprune」**という設計が、かなり生物に近い候補になります。

そしてこの考えだと「疑問を持つ」も自然に定義できます。

現在活動可能なサブネットワークのどれも予測誤差を十分下げられない状態

を検出したときに、通常モデル選択を止めて **variation 生成率を上げる**。

これは単なる比喩ではなく、「誤差が減らない → 構造可塑性を上げる」という閉ループとして人工系に落とせます。ここまでやると、かなり具体的な研究仮説になります。

    ...

ChatGPT は誤った情報を生成することがあります。ワークスペースのデータはモデルの学習には使用されません。